

셰프이어(ChefEar) 시스템 설계서

STT/TTS 도메인 파인튜닝 기반 음성 레시피 진행·등록 에이전트 — System Design Document

배포·실사용 중 — 현재 소스 기준

프로젝트	메인 프로젝트 — 딥러닝 기반 TTS-STT 서비스	문서 기준일	2026-08-27
팀 규모	3인 — 김승욱, 홍민하, 하주성	배포 범위	팀 내부 / 지도 강사 검토용
작성자	김승욱	착수일	2026-08-14

이 문서는 현재 배포되어 실사용 중인 소스 코드를 기준으로 시스템 아키텍처·데이터·인터페이스·기술 스택을 서술한다. STT(openai/whisper-large-v3-turbo)와 TTS(Qwen3-TTS-12Hz-1.7B)는 모두 QLoRA로 파인튜닝을 완료했고, 팀 GPU 데스크탑에서 상시 구동되며 실제 사용자 발화를 처리하고 있다.

● 목차

1. 개요 및 딥러닝 과제 범위	1
2. 범위 정의	2
3. 시스템 아키텍처	3
4. 기능 요구사항	4
5. 비기능 요구사항	5
6. 데이터 소스 및 데이터 모델	6
7. 인터페이스 명세	7
8. 기술 스택 및 배포 아키텍처	8
9. 팀 구성	9

1 개요 및 딥러닝 과제 범위

1.1 배경

공고 주제: 딥러닝 기반 TTS-STT 서비스 — 사전학습 모델을 API로 호출만 하는 것은 감점 대상, 도메인 데이터 기반 실제 파인튜닝 필수. 요리 경험이 거의 없는 사용자가 손을 쓰기 어려운 상황에서도 음성만으로 레시피를 진행할 수 있는 에이전트를 만드는 것이 목표다.

1.2 딥러닝 과제 범위

구분	범위	비고
파인튜닝	TTS — Qwen3-TTS-12Hz-1.7B	KSS 데이터셋 기반 QLoRA 파인튜닝 후 merge, HF Hub(kimseunguk/qwen3-tts-kss-finetuned)에 업로드해 배포에서 로드
파인튜닝	STT — openai/whisper-large-v3-turbo	QLoRA(4-bit NF4) 파인튜닝, 어댑터를 HF Hub(leeony/chefear-stt-large-v3-turbo)에 업로드. 배포는 CTranslate2 int8 변환 후 faster-whisper로 구동
임베딩 유사도 (비파인튜닝)	의도분류 — sentence-transformers(jhgan/ko-sroberta-multitask)	발화를 벡터화해 기준 예문과 코사인 유사도 비교. 서비스 응답 경로에서 외부 LLM API 호출 없음
로컬 LLM (자체 호스팅)	요리명 추정 + 등록 의도 판단 보조 — LGAI-EXAONE/EXAONE-3.5-2.4B-Instruct	팀 GPU에 transformers.AutoModelForCausalLM 으로 직접 로드. 외부 API 호출이 아님(1.4 참조)
실데이터	KADX/만개의레시피 재료 목록, 요리명, 인분수, 조회수(60,282개 고유 요리명 전량)	원문 그대로 사용
오프라인 사전 준비 (1회성, 배포 이전)	조리순서(COOKING_STEPS) 본문 텍스트	원본 데이터에 조리순서 컬럼이 없어 LLM(ChatGPT)로 재료 목록을 근거로 사전 작성. 배포된 서비스는 조회만 하고 런타임 생성은 하지 않음(6.2)

1.3 정의 및 대상 사용자(ICP)

ICP: 부모님과 따로 살기 시작한 직후, 요리를 거의 해본 적 없는 완전 초보 — 레시피 자체를 처음 접해 재료명·계량·순서 감각이 전혀 없는 사람.

JTBD: 요리 경험이 전무한 사람이, 처음 도전하는 요리에서 손이 바쁜 순간에도 화면을 다시 보지 않고 다음에 뭐 해야 할지 정확히 안내받아, 첫 시도부터 완성도를 잃지 않도록.

1.4 서비스 응답 경로에서 외부 LLM API 호출 배제 원칙

지도 강사 가이드에 따라, 배포된 서비스가 사용자 요청에 응답하는 경로에서 OpenAI·Anthropic·Gemini·Groq 등 외부 LLM API를 호출하는 코드는 산출물에 포함하지 않는다. 이 원칙은 "인터넷 건너 남의 서버로 텍스트를 보내 추론시키는 구조"를 막는 것이며, 팀이 소유한 GPU에 가중치를 직접 올려 완전히 로컬로 추론하는 것은 이 배제 대상이 아니다.

처리

방식

외부 API 여부

의도분류	sentence-transformers 임베딩 유사도 매칭	아님(경량 벡터 연산)
요리명 추정·등록 의도 보조 판단	팀 GPU에 직접 로드한 로컬 LLM(EXAONE-3.5-2.4B)	아님(완전 로컬 추론)
재료 대체·조리순서 제공	사전 적재된 실데이터 조회	해당 없음(생성 자체가 없음)

2 범위 정의

2.1 In-Scope

- 시작 인사말: 숫자선택 없이 자유발화 유도, 상시 마이크(WebRTC)로 세션 내내 계속 청취
- 조회: 동일 요리명 다건 시 조회수 1위를 표준으로 자동 채택(6.1, 되묻지 않음) → 진행 확인 → 1단계씩 짧게 안내 → "다음/다시/이전" 진행 제어
- 재료 대체(시작 시·진행 중 동일 로직): ① 요리명 정확 매칭 ② 재료 내용 기준 검색(6.4). 둘 다 실패하면 정직하게 "없다"고 안내. "취소해줘"로 직전 상태 롤백
- 조리 중에는 새 요리로 전환하지 않는다 — 다른 요리를 조회하려면 반드시 처음 화면으로 돌아가야 함
- 신규 등록(로그인 필요): 요리명 → 재료 → 재료 확인 체크포인트 → 순서 → 최종 확인 체크포인트
- 완료 시 원본 보존 + 수정본 user_custom 별도 저장, 다음 조회 시 개인 버전 우선
- 계정 로그인/회원가입, 마이 레시피 목록·수정·삭제
- 화면에 현재 단계·재료·최근 대화를 텍스트로 병행 표시
- 음성 인식/의도분류 실패 시 [이전][다시][다음] 수동 버튼으로 진행 흐름 복구
- TTS-STT 도메인 파인튜닝(계량단위 발음·짧은 안내 억양 등)

2.2 Could (스트레치 골)

- TTS 톤 다양화(감정 음성 데이터셋 활용)
- UI 시각적 완성도 향상

2.3 Out-of-Scope (Do-Not-Build)

- 사진으로 레시피 등록
- 서비스 응답 경로에서 외부 LLM API 호출(로컬 자체 호스팅 LLM은 예외, 1.4 참조)
- 표준 데이터(60,282건) 밖 요리의 조리순서 실시간 생성
- LLM의 자체 판단형 조언(궁합 등)
- TTS 발화 도중 끼어들기(바지인)
- 실제 판매·결제 연동, 자체 타이머, 자동 손 씻기 감지
- 특정 구역/섹션으로 점프하는 "이전" 기능, 조리 중 다른 요리로 전환

3 시스템 아키텍처

3.1 전체 처리 흐름

상시 마이크(WebRTC) 입력

- VAD(silero-vad)로 발화 구간 자동 분리
- STT(faster-whisper, CTranslate2 int8, 파인튜닝 어댑터 병합)
- 단위 표기 정규화 + 조리 문맥 기반 고위험 숫자 보정
- (조리 중이 아니면) 로컬 LLM(EXAONE)으로 요리명 추정 + 등록 의도 판단
- 임베딩 의도분류(sentence-transformers)
- 의도별 라우팅: 조회 / 진행·재청취·이전 / 재료대체 / 취소 / 등록
- 응답 텍스트 확정
- TTS(Qwen3-TTS, 파인튜닝) 합성 → 오디오 자동재생
- 화면(현재 단계·재료·대화 기록) 갱신

3.2 신규 등록 흐름

로그인 여부 확인(비로그인 시 진입 차단, 로그인 안내) → 요리명 질문 → 재료 질문 → 재료 확인 체크포인트 → 순서 질문 → 최종 확인 체크포인트 → user_custom 저장.

3.3 화면 구성

Streamlit 화면 컴포넌트로 구현되어 있으며, 화면 목록은 다음과 같다: start · recipe_confirm · cooking_step · cooking_complete · no_match · unclassified · register_intro · register_dish_name · register_ingredients · register_steps · complete · login · my_recipes · edit_recipe.

화면 구성 요소: ① 요리명+진행단계 배지 ② 재료 칩(대체된 재료는 별도 색상+"(대체)" 표시) ③ 현재 단계 카드(큰 글씨) ④ 최근 대화 자막 ⑤ 마이크 상태 표시줄 ⑥ [이전][다시][다음] 수동 제어 버튼(레시피 진행 중에만 노출).

3.4 상시 마이크 파이프라인

세션당 한 번만 마이크 연결(streamlit-webrtc)을 맺으면 화면이 전환돼도 같은 연결을 계속 사용한다. silero-vad 기반 세그먼트가 "말하다가 조용해지면 거기까지 한 발화"로 프레임을 잘라 STT에 넘긴다. AI가 TTS로 응답하는 동안에는 재생 길이만큼 마이크 입력을 일시적으로 무시해 자기 목소리를 다시 인식하지 않는다.

4 기능 요구사항

ID	요구사항	우선순위	비고
FR-01	시작 인사말은 자유발화 유도, 상시 마이크로 임베딩 유사도 매칭 기반 의도 판단	Must	외부 LLM API 호출 없음
FR-02	레시피 개요 확인 → 진행 확인 → 1단계씩 짧게 안내	Must	60,282건 실데이터 전량 기반
FR-03	"다음/다시/이전" 진행·재청취 표현 인식	Must	1단계에서 "이전" 요청 시 현재 단계 유지
FR-04	재료 대체(①요리명 매칭 ②재료내용 매칭), "취소해줘"로 롤백	Must	1:1 단순 치환까지, 동시 대체 최대 2개
FR-05	동일 요리명 다건 시 조회수 1위 자동 채택, 되묻지 않음	Must	23% 대표성 실측 확인
FR-06	신규 등록: 요리명→재료→재료확인→순서→최종확인 2단계 체크포인트	Must	로그인 계정 필요(FR-18)
FR-08	완료 시 원본 보존 + user_custom 별도 저장, 다음 조회 시 개인 버전 우선	Must	로그인 계정 id 또는 익명 쿠키 UUID 기준
FR-09	Whisper STT 도메인 파인튜닝 및 배포 구동	Must	QLoRA(4-bit NF4) → CTranslate2 int8, GPU 구동
FR-10	Qwen3-TTS 도메인 파인튜닝 및 배포 구동	Must	KSS 기반 QLoRA → merge, GPU 구동
FR-11	TTS-STT 파인튜닝 전/후 정량 평가(WER/CER) 및 반복 테스트	Must	완료정의 보조 기준
FR-13	화면에 현재 단계·재료·최근 대화를 텍스트로 병행 표시	Must	Streamlit 구현
FR-14	숫자+단위 조합("1.5컵" 등) 정확 인식	Must	STT 단위 정규화 + 조리 문맥 기반 고위험 수량 보정
FR-15	임베딩 기반 의도분류용 기준 예문 세트 구축·유지	Must	data/intent_examples/기준예문.csv
FR-16	음성 인식/의도분류 실패 시 [이전][다시][다음] 수동 대체 UI	Must	레시피 진행 중에만 노출
FR-17	로컬 LLM(EXAONE) 기반 요리명 추정 및 등록 의도 판단 보조	Must	외부 API 아님. 실패 시 안전한 기본값으로 폴백
FR-18	계정 로그인/회원가입 및 마이 레시피(등록/수정/삭제)	Must	PBKDF2-HMAC-SHA256 해시, users 테이블
FR-19	상시 마이크(WebRTC) 입력 및 자동 발화 구간 분리(VAD)	Must	세션당 한 번 연결, 화면 전환에도 유지
FR-20	조리 중 레시피 전환 금지	Must	새 요리는 처음 화면에서만 조회 가능

5 비기능 요구사항

구분	요구사항	기준
제품 성공 기준(주)	손에 재료가 묻거나 도구를 쥔 상태에서도 화면 없이 흐름이 끊기지 않는가	동일 시나리오 반복 테스트(정성)
제품 성공 기준(보조)	동일 질의 반복 시 정확한 레시피/재료 반영 비율	반복 테스트(10~20회) 정량화
딥러닝 성능	TTS 파인튜닝 효과	계량단위 발음·짧은 안내 역양 자연스러움, TTS→STT 재인식 CER
딥러닝 성능	STT 파인튜닝 효과	파인튜닝 전/후 WER·CER 개선폭 실측
성능	1단계 안내 응답 시간	5초 이내
인프라	배포 환경	팀 GPU 데스크탑(RTX 5070, 12GB VRAM) 상시 구동
데이터 적합성	레시피 메타데이터 출처	KADX/만개의레시피(공식 유통) 단일 소스 실데이터
동시성	GPU 자원 공유	STT·임베딩·로컬 LLM·TTS 모델 종류별 락으로 동시 추론 직렬화

6 데이터 소스 및 데이터 모델

6.1 데이터 소스 및 표준 선정 규칙

소스	역할	비고
KADX 만개의레시피 CSV	레시피 메타데이터(요리명·재료·인분수·조회수) 시드	중복 제거 후 234,538건 고유 레시피, 60,282개 고유 요리명
요리명별_조리과정_60282건.csv	조리순서(COOKING_STEPS) 소스	요리명별 조회수 1위 기준으로 60,282개 고유 요리명 전량 조리순서 포함

표준 레시피 선정 규칙: 동일 요리명 다건 존재 시 조회수 1위를 표준으로 자동 채택, 되묻지 않음. 실데이터 검증: "된장찌개" 444건 중 1위가 전체 조회수의 23.0%를 차지, 대표성 확인됨.

6.2 조리순서 데이터 구성

`recipes` 테이블에 60,196건, `recipe_steps` 테이블에 357,938건이 적재되어 있다. 요리명·재료·인분수·조회수 등 메타데이터는 원본 CSV의 실데이터 그대로다. 조리순서 본문 문장은 원본 데이터에 해당 항목이 없어, 배포 이전 단계에서 LLM(ChatGPT)이 재료 목록을 바탕으로 작성해 채워 넣었다 — 서비스가 실행되기 전에 끝난 1회성 오프라인 데이터 준비이며, `source=api_standard` 로 함께 태깅된다. 배포된 서비스는 준비된 `recipe_steps` 를 조회만 할 뿐 런타임에 생성하지 않는다.

6.3 재료 대체 검색 로직

순서	검색 기준	신뢰도
①	요리명 정확 매칭(예: "바지락"+"된장찌개" → "바지락된장찌개")	실데이터
②	요리명에 없으면 재료 목록 내용 기준 검색(요청 재료 전부 포함 AND, 제외 재료 NOT)	실데이터
③	①②모두 없으면 정직하게 "해당 조합의 레시피가 없습니다" 안내	생성 없음

6.4 조리순서 서비스 범위

60,282개 고유 요리명 전체에 대해 조리순서를 사전 적재해 두었으므로, 표준 레시피로 선정되는 모든 요리명에 대해 조리순서를 제공한다. 표준 데이터 밖의 요리명을 요청하면 정직하게 "레시피가 없다"고 안내하고, 로그인 상태라면 신규 등록 흐름으로 유도한다.

6.5 의도분류 임베딩 유사도 매칭

sentence-transformers(jhgan/ko-sroberta-multitask)로 발화를 벡터화하고, 의도별 기준 예문과 코사인 유사도를 비교해 가장 가까운 의도를 선택한다. 의도: 조회 · 등록 · 진행 · 재청취 · 이전 · 재료대체 · 취소 · 감탄사(무시) · 미분류(재질문). 판정은 threshold(1위 유사도 기준)와 margin(1위·2위 차이 기준)을 함께 사용한다. 조리 중에는 "조회"·"등록"으로 분류되는 발화를 무시하고 현재 레시피를 유지한다.

6.6 Supabase 테이블

테이블	컬럼	설명
-----	----	----

recipes	id, dish_name, ingredients, source, origin_id, view_count, external_id, servings, owner_id, created_at	레시피 1건당 1행. source는 api_standard/user_custom
recipe_steps	recipe_id, step_number, step_text, source	레시피 1건당 여러 행(단계별)
users	id, username, password_hash, created_at	계정 로그인용, 비밀번호는 PBKDF2 해시로만 저장

벡터검색은 SQL 함수 없이 Python(supabase-py 필터)에서 조립한다. Supabase 자격증명이 없으면 인메모리 mock 클라이언트로 자동 대체된다.

7 인터페이스 명세

함수	위치	입력 → 출력
stt_transcribe()	src/stt/infer.py	오디오 → 텍스트(단위 정규화·고위험 수량 보정 적용)
extract_intent_llm()	src/orchestration/entity_extract_llm.py	발화 텍스트 → {dish_name, wants_register} (로컬 LLM)
classify_intent()	src/orchestration/intent_classifier.py	발화, context_recipe_id → intent, similarity_score
extract_dish_name()	src/orchestration/recipe_search.py	발화 텍스트 → DB에 실존하는 요리명 또는 없음(3단계 보정)
extract_substitution_ingredients()	src/orchestration/entity_extract.py	발화 텍스트 → (요청 재료 목록, 제외 재료)
select_standard_recipe()	src/orchestration/recipe_search.py	요리명, owner_id → 표준(또는 본인 user_custom 우선) 레시피
search_variant_recipe() / search_by_ingredient_content()	src/orchestration/recipe_search.py	base_recipe_id, 요청/제외 재료 → match_type
apply_substitution() / cancel_substitution()	src/orchestration/substitution.py	session, match → 세션의 현재/직전 recipe_id 갱신·롤백
get_precomputed_steps() / get_current_step() / advance_step()	src/orchestration/pipeline.py	recipe_id, step_number, 방향 → 조리순서/다음 상태
register_recipe() / save_recipe() / update_recipe() / delete_recipe()	src/orchestration/registration.py	요리명, 재료, 순서 등 → recipe_id, 저장/수정/삭제 결과
create_user() / authenticate_user()	src/orchestration/auth.py	username, password → 계정 정보 또는 없음
get_or_create_anon_id()	src/orchestration/identity.py	cookies → 익명 쿠키 UUID
tts_synthesize()	src/tts/infer.py	텍스트 → (waveform, sample_rate)

7.1 진행 단계 상태 전이

현재 step_number=N일 때: 다음 → N+1 / 다시 → N 유지 / 이전 → max(1, N-1), 1단계에서는 유지하고 "이전 단계 없음" 안내. 재료대체 후에도 변경된 recipe_id와 현재 step_number 기준으로 동일 규칙이 적용된다. 마지막 단계에서 "다음"을 요청하면 완료 화면으로 이동한다.

7.2 재료 대체 응답 형식

```
// 매칭 성공
{ "match_type": "exact_name" | "ingredient_content",
  "result_recipe_id": string, "result_dish_name": string, "source": "api_standard" }

// 매칭 실패
{ "match_type": "none", "message": "죄송해요, 이 조합의 레시피는 없어요." }
```

7.3 신규 등록 상태 기계

`register_recipe(session, step, value)` 가 step 값에 따라 동작한다: `dish_name` (등록 시작) → `ingredients` (여러 턴 누적, 재료 확인 체크포인트 반환) → `instructions` (여러 턴 누적, 최종 확인 체크포인트 반환) → `confirm` (저장) / `abort` (폐기). 동일 요리명으로 이미 `user_custom`이 있어도 덮어쓰지 않고 새 `recipe_id`로 별도 저장한다.

8 기술 스택 및 배포 아키텍처

8.1 버전 고정

구분	패키지	버전	비고
언어	Python	3.12(env-main)	STT 학습 환경만 3.11.9 확인, 서비스 실행 venv는 3.13
실행/배포	streamlit	1.61.1	엔트리포인트 src/app.py
임베딩(의도분류)	sentence-transformers	5.6.1	jhgan/ko-sroberta-multitask
STT 추론(배포)	faster-whisper	1.2.1	CTranslate2 int8, GPU 구동
STT 학습·로컬 LLM 공유 스택	transformers / peft / bitsandbytes / accelerate	4.57.3 / 0.20.0 / 0.50.0 / 1.12.0	Whisper QLoRA와 EXAONE 로컬 추론 공유
TTS 추론(배포)	qwen-tts	0.1.1	Qwen3TTSTModel, GPU(bfloat16)
STT·TTS 평가	jiwer	4.0.0	WER/CER 전/후 비교
DB	supabase	2.31.0	SQL RPC 미사용, Python 필터만
상시 마이크	streamlit-webrtc / silero-vad / aiortc	0.77.0 / 6.2.1 / 1.15.0	브라우저 마이크 스트리밍 + 발화 구간 자동 분리
쿠키(개인화·로그인 유지)	streamlit-cookies-manager	0.2.0	암호화된 쿠키

8.2 배포 아키텍처

배포는 팀 GPU 데스크탑(RTX 5070, 12GB VRAM) 한 대에서 Streamlit 서비스와 STT·TTS·임베딩·로컬 LLM 모델을 모두 상시 구동하는 방식이다. 넷 다 같은 GPU를 공유하므로, 모델 종류별 락으로 동시 추론을 직렬화해 자원 경합을 막는다. 모델 가중치는 Hugging Face Hub에서 앱 시작 시 내려받아 캐시하고, 데이터는 전량 Supabase에 저장한다.

외부 접속은 Cloudflare Tunnel로 공개 도메인(chefear.store)을 통해 이 GPU 데스크탑에 연결된다. 별도 랜딩페이지(chefear-landingpage.vercel.app)를 거쳐 접속 링크로 안내하며, 접속 토큰(ACCESS_GATE_TOKEN)을 설정하면 그 토큰이 붙은 URL로만 접근을 허용하는 약한 접근 제어를 둘 수 있다. WebRTC 마이크 연결은 Cloudflare Realtime TURN을 우선 사용하고, 없으면 자체 TURN 또는 구글 공개 STUN으로 대체된다.

8.3 기술 선택 근거

항목	선택	근거
STT 베이스	openai/whisper-large-v3-turbo	Whisper Small, wav2vec2와 비교 실험 후 요리 도메인에서 가장 안정적인 WER/CER 확보
TTS 베이스	Qwen3-TTS-12Hz-1.7B	Apache 2.0 라이선스, 한국어 지원, 짧은 문장 보이스클로닝에 적합
의도분류	임베딩 유사도(sentence-transformers)	지도 강사 가이드에 따라 외부 LLM 런타임 사용 배제, 정해진 명령어 없이 자유발화 이해
요리명 추정 보조	로컬 LLM(EXAONE-3.5-2.4B)	온디바이스/경량 배포용 한국어 네이티브 모델, 외부 API 미사용

배포 인프라	팀 GPU 데스크탑 + Cloudflare Tunnel	Qwen3-TTS(1.7B)를 CPU 전용 무료 인프라로 목표 응답시간(5초) 안에 구동하기 어려워 GPU 상시 노출 방식 채택
벡터검색	Python 필터(SQL RPC 미사용)	팀 내 SQL 활용도를 고려한 선택

9 팀 구성

역할	담당	책임
오케스트레이션/통합(조장)	김승욱	의도분류, 단계 진행·재료대체·등록 로직, 로컬 LLM 연동, Supabase 연동, 배포·통합
TTS 파인튜닝/UI	홍민하	Qwen3-TTS-12Hz-1.7B + KSS 파인튜닝, Streamlit UI 구현
STT 파인튜닝	하주성	Whisper Small-wav2vec2 비교 실험, whisper-large-v3-turbo QLoRA 파인튜닝, WER/CER 평가

본 문서는 docs/ChefEar_PRD_SDD_v0.8.md와 함께 팀 내부 및 지도 강사 검토용으로 배포된다.