

음성 · 텍스트 입력에 따른 생성 결과물

실제 조리 대화 시나리오(입력 발화 → 파이프라인 처리 → 응답)와, STT·TTS 파인튜닝 모델이 실제 음성·텍스트 입력을 받아 생성한 결과물의 실측 지표, 그리고 권장 정량·정성 평가 지표 대비 실제 반영 현황을 함께 정리했습니다.

01 대화 시나리오 예시

PRD 사용자 시나리오 기준 · 자유발화 입력이 의도분류를 거쳐 응답으로 이어지는 실제 흐름. 로그인·계정 개념은 없으며, 조회는 누구나 가능하고 신규 등록은 관리자 승인 후 모두에게 공개됩니다.

 사용자 여정

1 진입

손에 재료가 묻은 채로 음성만으로 시작 · WebRTC로 오디오 스트림 캡처

2 조회

자유발화로 요리를 물으면 표준 레시피를 안내 (SCENARIO A)

3 진행

"다음" 발화마다 한 단계씩 안내받으며 요리

4 예외

표준 데이터에 없는 요리를 물으면 화면 전환 없이 현재 화면에 머문 채 "등록되지 않은 레시피예요. 새로 등록을 원하시면 '레시피 등록'이라고 말씀해 주세요."라고 안내. "레시피 등록"이라고 말하면 바로 요리명 입력 화면으로 전환됨(확인 질문 없음) (SCENARIO B)

5 종료

재료·순서 입력 후 "네, 저장할게요"를 누르면 저장은 되지만 "관리자 승인 후에 검색할 수 있어요"라는 안내가 나오고, 승인 전까진 등록된 사람 포함 아무도 조회할 수 없음. 승인되면 그 순간부터 등록자·타인 구분 없이 누구나 동일하게 조회 가능 (SCENARIO C·D)

🗨 사용자 · 대화 예시

SCENARIO A — 조회 및 진행

사용자

"된장찌개 어떻게 만들어?"

ChefEar

"된장찌개, 조회수 1위 표준 레시피예요. 이걸로 시작할까요?"

사용자

"응"

ChefEar

"느타리버섯, 애호박, 두부를 먹기 좋은 크기로 썰어주세요. (이후 '다음' 발화마다 한 단 계씩 진행)"

SCENARIO B — 표준 데이터 밖 요청 → 등록 유도

사용자

"문어초무침 어떻게 만들어?" (60,282건 표준 데이터에도 없는 요리명)

ChefEar

"등록되지 않은 레시피예요. 새로 등록을 원하시면 '레시피 등록'이라고 말씀해 주세요."

사용자

"레시피 등록"

(요리명 입력 화면으로 전환 — 별도 안내 음성 없음)

SCENARIO C — 승인 대기 중 재조회

사용자

"문어초무침 어떻게 만들어?"

ChefEar

"등록 심사 중인 레시피예요. 승인되면 바로 조회할 수 있어요."

SCENARIO D — 관리자 승인 후 재조회

사용자

"문어초무침 어떻게 만들어?"

ChefEar

"문어초무침, 조회수 1위 표준 레시피예요. 이걸로 시작할까요?"

(승인 후에는 등록자·타인 구분 없이 누구나 SCENARIO A와 동일한 응답을 받음)

02 STT 생성 결과 · 실제 인식 성능

Whisper Large-v3-turbo QLoRA 최종 모델(MIX750)이 신규500 평가셋을 실제로 인식한 결과

신규500 WER 10.72%	신규500 CER 2.26%	재료명 인식률 98.31%	조리동작 인식률 99.54%
----------------------------	---------------------------	--------------------------	---------------------------

평가 항목	인식 성공률	의미
숫자·단위	90.57%	수량과 계량 단위(예: "1.5컵", "5분") 인식
재료명	98.31%	레시피 재료명 인식
조리동작	99.54%	"볶다·끓이다·썰다" 등 조리 행동 표현 인식
핵심정보 종합	96.23%	ChefEar 조리 안내에 필요한 핵심정보 종합 인식률

기준 2에폭(WER 33.20%) → train300 → train1000 → reinforce250을 거쳐, Replay 500개 + 숫자보장 250개를 추가 학습한 MIX750을 최종 모델(BEST_FINAL_mix750_replay_numeric)로 선정했습니다. train1000이 Fixed100 WER(7.26%)은 더 낮았지만 숫자·단위 인식률이 86.79%에 그쳐, 일반화 성능과 도메인 인식률을 함께 만족하는 MIX750을 택했습니다.

03 TTS 생성 결과 · ROUND-TRIP 검증

실제 조리 문장 5개를 TTS로 합성한 뒤 다시 STT로 되돌려(round-trip) 원문과 비교한 실측 결과

입력 텍스트	TTS → STT 재인식 결과	CER
약불로 5분간 끓여주세요	약불로 5분간 끓여주세요.	0.0000
양파와 마늘을 다진 뒤, 팬에 기름을 두르고 중불에서 노릇하게 볶아주세요	양파와 마늘을 다진 뒤 팬에 기름을 두르고 중불에서 노릇하게 볶아주세요.	0.0000
1.5컵의 물을 넣고 뚜껑을 덮은 채로 10분간 졸인 다음, 불을 끄고 5분 정도 뜸을 들여주세요	1.5 컵의 물을 넣고 뚜껑을 덮은 채로 10분간 졸인 다음 불을 끄고 5분 정도 뜸을 들여주세요.	0.0000
두부와 감자를 먹기 좋은 크기로 썰어 넣습니다	두부와 감자를 먹기 좋은 크기로 썰어넣습니다.	0.0000
된장을 풀어줍니다	된장을 풀어줍니다.	0.0000

문장부호· 띄어쓰기 차이만 있을 뿐 음절 단위 오류(CER)는 5문장 모두 0.0000 · 13에폭크 voice-clone 체크포인트 기준.

04 TTS 배포 환경별 추론 속도 비교

동일 입력 문장을 CPU와 로컬 GPU 배포 환경에서 각 3회 반복 실측한 평균 추론 시간

CPU 배포 15.0초 "약불로 5분간 끓여주세요" 평균 (16.40 / 13.52 / 15.17초) · 목표(5초) 대비 3배 초과	GPU 배포 (로컬 GPU) 4.2초 동일 문장 평균 (4.77 / 4.03 / 3.67초) · 목표(5초) 이내로 개선
---	--

RESULT CPU 배포로는 목표 응답속도(5초)를 맞추지 못해 GPU 기반 배포로 전환했습니다. 긴 문장("양파와 마늘을 다진 뒤...")은 CPU 기준 28~34초까지 늘어나 실사용에 부적합했고, 동일 문장의 GPU 추론은 7~8초대로 단축됩니다.

05 정량·정성 평가 지표 반영 현황

권장 평가 지표(8-1 정량 / 8-2 정성) 기준으로 ChefEar가 실제 측정·반영한 항목을 정리했습니다.

영역	권장 지표	측정 방법·도구	CHEFEAR 반영 현황
STT	WER / CER	jiwer 라이브러리, 신규500 벤치마크	측정 완료 · WER 10.72% / CER 2.26%
TTS	MOS (평균의견점수)	5점 척도 청취 평가, 자체 설계 평가지	측정 완료 · 평가자 13명 × 909건
TTS	RTF (Real-Time Factor)	1초 음성 생성에 걸리는 시간	부분 측정 · CPU 15.0초/GPU 4.2초 · TTS 비교실험 RTF 산출: vits-kss만 RTF<1(실시간)
TTS	SIM (화자 유사도)	Voice Cloning 시 임베딩 코사인 유사도	해당 없음 · Zero-shot Voice Cloning이 아닌 KSS 데이터셋 파인튜닝 방식
전체	Latency (TTFB)	입력부터 첫 출력까지의 시간	미측정

정성 지표(자연스러움 · 발음정확도 · 감정·톤표현 · 일관성)는 항목별 개별 측정 대신, 이를 종합적으로 반영하는 5점 척도 MOS 청취평가로 대체 측정했습니다.

TTS MOS 청취평가 결과 (모델별 비교)

지인·친구·가족 자취생 13명이 동일한 10개 문장 세트를 모델별로 블라인드 청취 후 5점 척도로 평가한 실측 결과 (총 909 건)

모델	평균 MOS	평가 건수
Qwen3-TTS-1.7B-Base LoRA FT · ChefEar 실사용 모델	4.67	130
Qwen3-TTS · Base	4.33	129
Qwen3-TTS · QLoRA FT	4.17	130
Qwen3-TTS · Full FT	2.10	130
vits-kss	1.45	130
Chatterbox · Full FT	1.05	130
Chatterbox · LoRA FT	1.04	130

ChefEar 실사용 모델(Qwen3-TTS-1.7B-Base LoRA FT)은 STT 재인식용 hypothesis 없이 완성된 음성만 직접 청취 평가했고, 나머지 비교 모델은 청취 평가와 함께 TTS 출력을 STT로 재인식한 WER-CER도 함께 수집했습니다. ChefEar 모델이 평균 MOS 4.67로 비교군 중 가장 높았습니다.

ChefEar · AI Human 771 A조

Generation Output